

# Classifiez automatiquement des biens de consommation

PROJET 6
EMANUELE PARTENZA

## Etude de faisabilité d'un moteur de classification

#### Texte:

CountVectorizer

**TfidVectorizer** 

Word2Vec

**BERT** 

USE

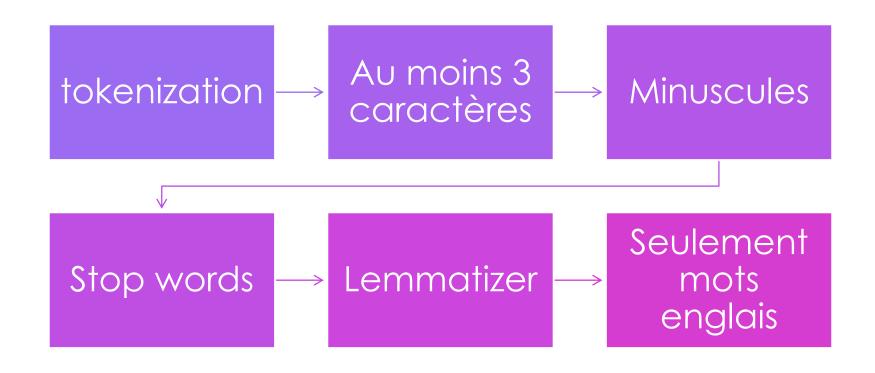
#### Image:

- ORB
- ResNet50
- ▶ VGG16



### Data Frame

#### Nettoyage du texte



#### Bag of words

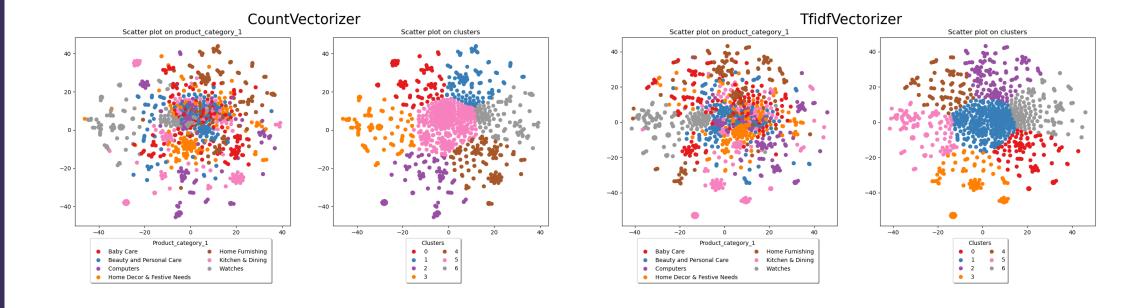
#### CountVectorizer

Transforme le corpus en une matrice de comptage des mots

#### **TfidVectorizer**

Transforme le corpus en une matrice dans laquelle à chaque mot est associé, non plus sa fréquence, mais un poids.

Ce poids correspond à la fréquence fois l'indicateur idf (inverse document frequency).



#### CountVectorizer

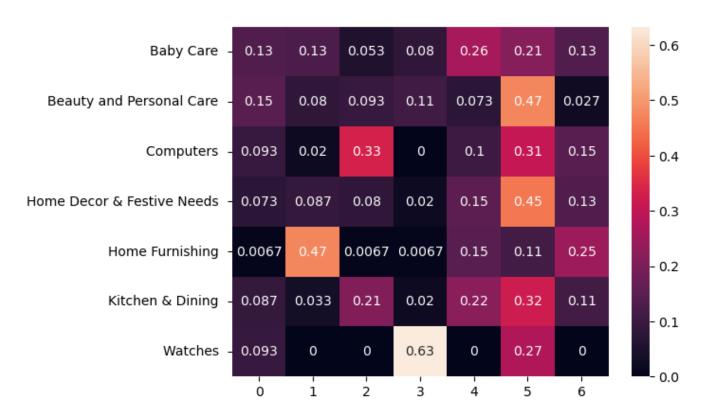
#### SCORES:

► ARI: 0.110

F1:0.143

Precision: 0.152

Recal: 0.147



#### TfidVectorizer

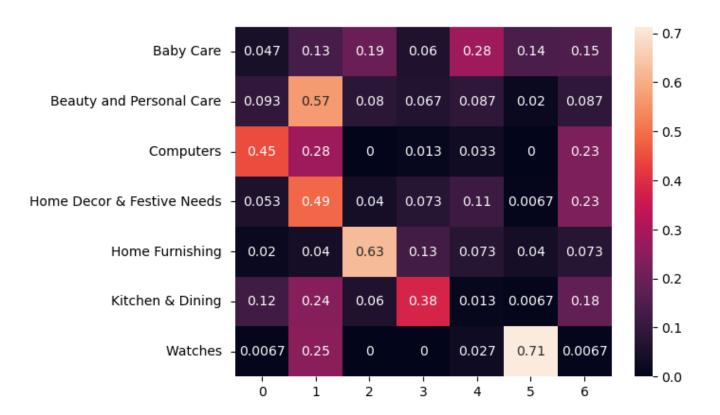
#### SCORES:

► ARI: 0.188

F1:0.088

Precision: 0.082

Recal: 0.110

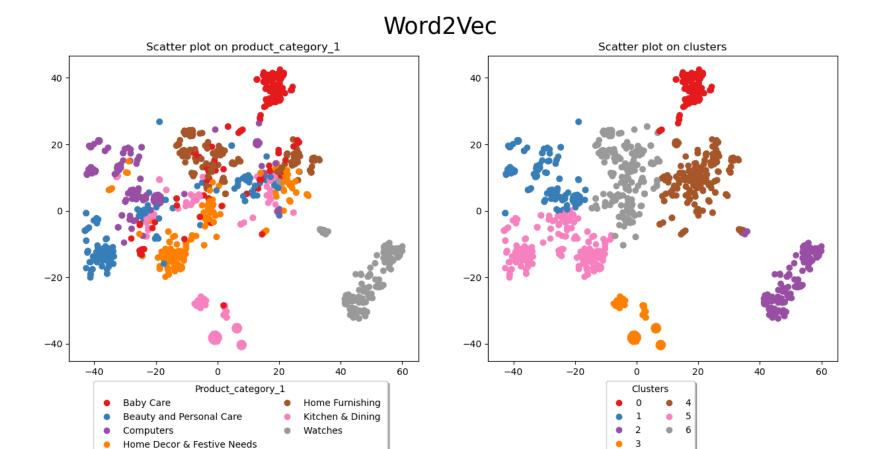


#### Word2Vec

Ce modèle essaye de prendre en compte le contexte dans lequel le mot a été trouvé.

Il le fait en combinant deux techniques:

- CBOW (Continuous Bag of Words) qui entraine le réseau de neurones pour prédire un mot en function du contexte;
- Skip-gram qui essaye de prédire le contexte en fonction du mot.



#### Word2Vec

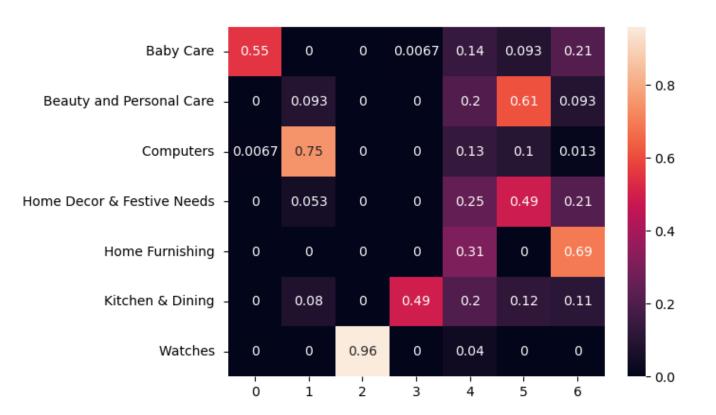
#### SCORES:

ARI: 0.385

► F1:0.167

Precision: 0.201

Recal: 0.153

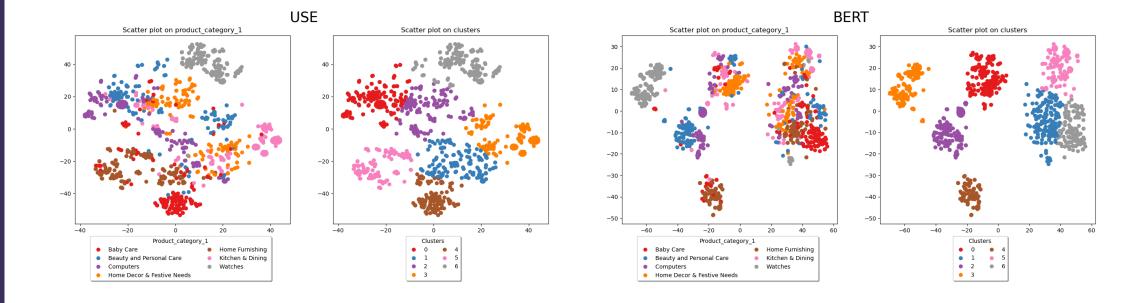


#### BERT & USE

BERT (Bidirectional Encored Représentations from Transformers)

USE (Universal Sentence Encoder)

Ce sont deux modèles préentrainés



#### Scores

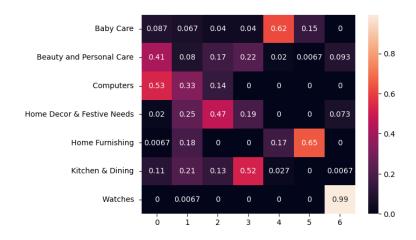
#### USE

► ARI: 0.361

► F1: 0.226

► Precision: 0.219

► Recal: 0.236



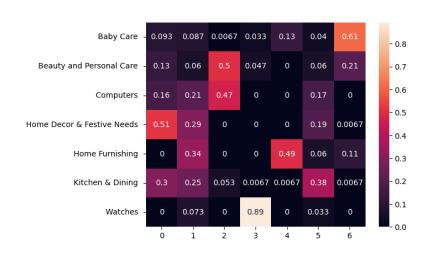
#### **BERT**

► ARI: 0.301

► F1: 0.228

► Precision: 0.253

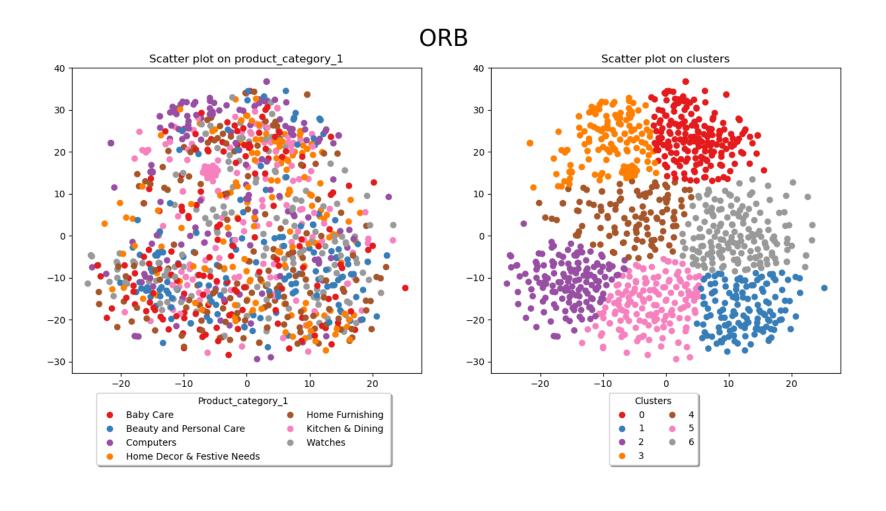
▶ Recal: 0.213



#### ORB

L'algorithmes ORB (Oriented FAst and Rotated BRIEF) nous permets d'extraire des features des images et de calculer leurs descripteurs.

Cette méthodes est la fusion de FAST, pour la detection des keypoints, et de BRIEF pour les descripteurs.



#### ORB

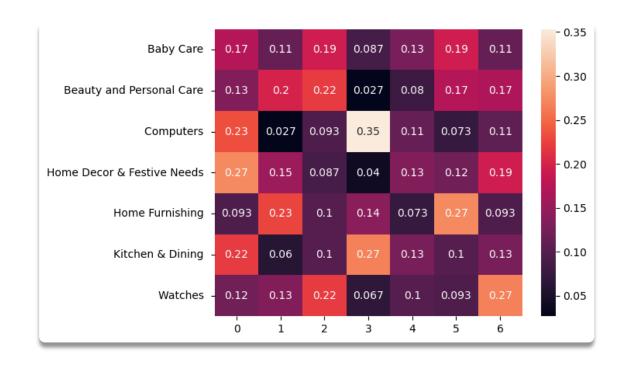
#### SCORES:

► ARI: 0.032

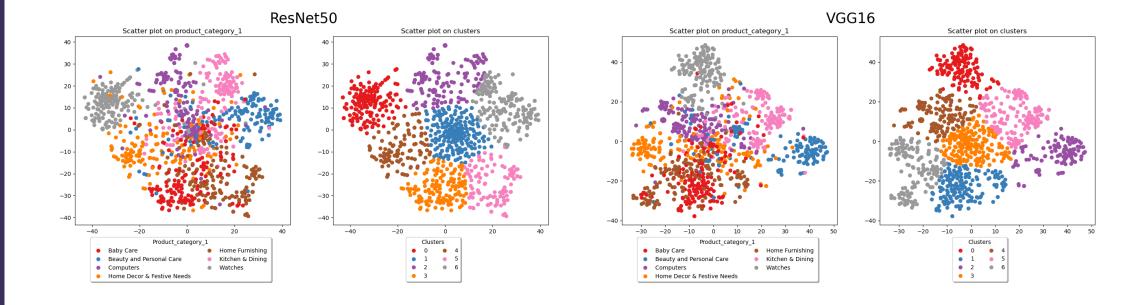
► F1:0.133

▶ Precision: 0.133

► Recal: 0.135



ResNet50 & VGG16 ResNet50 (deep Residual Networks) et VGG16(Visual Geometry Group) sont deux modèles pré-entrainés utilisant un réseau de neurones convolutif (CNN)



#### Scores

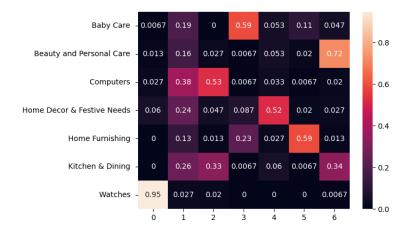
#### ResNet50

► ARI: 0.371

► F1:0.116

▶ Precision: 0.116

► Recal: 0.117



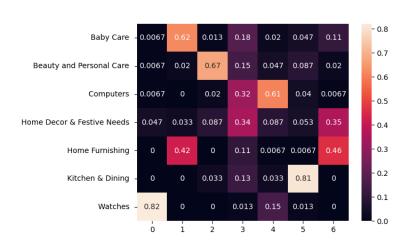
#### VGG16

► ARI: 0.394

► F1:0.164

Precision: 0.257

▶ Recal: 0.171



# Merci pour votre attention